

Segmentação Automática de Lesões de Pele utilizando Redes Neurais Convolucionais U-Net

Daniel Souza Crisostomo¹

¹ Instituto Federal de Educação, Ciência e Tecnologia do Piauí (IFPI)
Corrente – PI – Brasil

danielsouza.c024@gmail.com

Resumo. O câncer de pele representa uma das doenças oncológicas de maior incidência no mundo, tornando indispensável o desenvolvimento de ferramentas computacionais capazes de auxiliar especialistas durante o processo de diagnóstico. Neste trabalho é proposta uma abordagem baseada em Redes Neurais Convolucionais utilizando a arquitetura U-Net para segmentação automática de lesões dermatológicas presentes no conjunto de dados ISIC 2018. O modelo foi treinado empregando técnicas de aumento de dados, normalização das imagens e transferência de aprendizado em ambiente Google Colaboratory. Como função de perda utilizou-se a combinação entre Binary Cross Entropy e Dice Loss. Os resultados experimentais demonstraram Dice Coefficient de aproximadamente 0,77, IoU superior a 0,68 e precisão superior a 96%, indicando elevada capacidade de delimitação das regiões lesionadas e demonstrando a eficiência da arquitetura proposta para aplicações em sistemas inteligentes de apoio ao diagnóstico médico.

Abstract. Skin cancer is among the most common types of cancer worldwide, making the development of intelligent computer-aided diagnosis systems increasingly important. This work proposes an automatic skin lesion segmentation method based on the U-Net convolutional neural network using the ISIC 2018 dataset. The proposed methodology employs image preprocessing, data augmentation, transfer learning techniques, and Binary Cross Entropy combined with Dice Loss during optimization. Experimental results achieved a Dice coefficient of approximately 0.77, Intersection over Union greater than 0.68 and precision above 96%, demonstrating the robustness of the proposed approach for assisting dermatological diagnosis.

1. Introdução

O câncer de pele constitui atualmente uma das doenças mais frequentes em diversos países, sendo responsável por milhões de novos casos diagnosticados anualmente. Segundo a Organização Mundial da Saúde (OMS), a detecção precoce aumenta significativamente as chances de tratamento e reduz a mortalidade associada à doença [World Health Organization 2023]. Entretanto, o processo tradicional de diagnóstico depende da experiência do dermatologista e da análise visual de imagens dermatoscópicas. Em muitos casos, pequenas variações de textura, cor, formato e bordas tornam a identificação das lesões uma tarefa complexa, principalmente em estágios iniciais da doença [Celebi et al. 2019].

Nos últimos anos, os avanços obtidos na área de Inteligência Artificial, especialmente em Aprendizado Profundo (Deep Learning), permitiram o desenvolvimento de modelos capazes de aprender automaticamente características relevantes diretamente das imagens médicas, eliminando grande parte da necessidade de engenharia manual de atributos [LeCun et al. 2015]. Dentro desse contexto, destacam-se as Redes Neurais Convolucionais (CNNs), amplamente utilizadas em tarefas de classificação, detecção e segmentação de imagens médicas. Entre essas arquiteturas, a U-Net tornou-se uma das mais empregadas devido à sua elevada capacidade de localizar precisamente regiões anatômicas de interesse, mesmo utilizando conjuntos relativamente pequenos de treinamento [Ronneberger et al. 2015].

A segmentação automática consiste em identificar exatamente quais pixels pertencem à lesão e quais pertencem à pele saudável. Diferentemente da classificação, que apenas informa se existe ou não uma lesão, a segmentação fornece informações espaciais extremamente importantes para o cálculo de área, perímetro, irregularidade das bordas e evolução temporal da doença. Apesar dos excelentes resultados apresentados pela literatura, desafios permanecem presentes, tais como a elevada variabilidade entre os tipos de lesão, diferenças de iluminação durante a aquisição das imagens, presença de pelos, sombras e reflexos, além do baixo contraste entre pele saudável e região lesionada e as diferentes resoluções das imagens. Esses fatores tornam a segmentação automática um problema complexo de Visão Computacional.

Diante desse cenário, este trabalho propõe o desenvolvimento de um sistema baseado na arquitetura U-Net para realizar a segmentação automática de lesões de pele utilizando imagens provenientes do desafio ISIC 2018. Como objetivos específicos, pretende-se aplicar técnicas de pré-processamento nas imagens, utilizar aumento artificial de dados (Data Augmentation), treinar uma arquitetura U-Net em ambiente Google Colaboratory, avaliar o desempenho utilizando Dice Coefficient, IoU, Precisão, Sensibilidade e Especificidade, e comparar visualmente as máscaras preditas com as máscaras reais do conjunto de dados. Espera-se que os resultados obtidos possam contribuir para o desenvolvimento de sistemas inteligentes de apoio ao diagnóstico dermatológico, reduzindo o tempo necessário para análise clínica e auxiliando especialistas durante a tomada de decisão.

2. Fundamentação Teórica

2.1. Câncer de Pele

O câncer de pele é caracterizado pelo crescimento anormal das células cutâneas, podendo ser classificado em melanoma e não melanoma. O melanoma apresenta menor incidência, porém elevada taxa de mortalidade quando diagnosticado tardiamente [American Cancer Society 2024]. A análise dermatoscópica tornou-se uma das principais ferramentas utilizadas por dermatologistas, permitindo visualizar estruturas internas invisíveis a olho nu. Entretanto, sua interpretação ainda depende da experiência do profissional, tornando desejável a utilização de sistemas automáticos de apoio ao diagnóstico.

2.2. Visão Computacional aplicada à Medicina

A Visão Computacional busca desenvolver algoritmos capazes de interpretar automaticamente informações presentes em imagens digitais. Na área médica, essa tecnologia vem sendo aplicada em tarefas como segmentação de tumores, classificação de doenças,

detecção de anomalias, análise histopatológica e diagnóstico assistido por computador. Com o avanço das GPUs e das técnicas de Deep Learning, tornou-se possível treinar modelos extremamente complexos utilizando milhares de imagens médicas em tempo relativamente reduzido.

2.3. Redes Neurais Convolucionais

As Redes Neurais Convolucionais (CNNs) são arquiteturas especializadas no processamento de imagens. Essas redes utilizam operações de convolução capazes de aprender automaticamente características como bordas, texturas, padrões, formas e estruturas complexas. Diferentemente dos métodos tradicionais de Visão Computacional, nos quais os atributos precisavam ser extraídos manualmente, as CNNs realizam esse aprendizado durante o próprio treinamento [Goodfellow et al. 2016].

2.4. Arquitetura U-Net

A arquitetura U-Net foi proposta por Ronneberger et al. [Ronneberger et al. 2015] para segmentação biomédica. Sua estrutura apresenta formato em "U", sendo composta por duas partes principais: um Caminho de Contração (Encoder) e um Caminho de Expansão (Decoder). Durante o Encoder são extraídas características cada vez mais abstratas por meio de convoluções e operações de MaxPooling. No Decoder ocorre a recuperação da resolução espacial utilizando UpSampling e conexões do tipo Skip Connections, responsáveis por preservar detalhes importantes perdidos durante a etapa de redução. Essa arquitetura tornou-se referência em problemas de segmentação médica devido à excelente precisão obtida mesmo em conjuntos de dados relativamente pequenos.

2.5. Métricas de Avaliação

Para avaliar o desempenho do modelo foram utilizadas métricas amplamente empregadas em segmentação semântica. O Dice Coefficient mede a sobreposição entre a máscara prevista e a máscara real, enquanto a métrica IoU (Intersection over Union) calcula a razão entre a área de interseção e a área de união das máscaras. Também foram utilizadas as métricas de Precisão (Precision), Sensibilidade (Recall) e Especificidade (Specificity). Essas métricas permitem avaliar diferentes aspectos do desempenho do modelo, fornecendo uma análise mais completa da qualidade da segmentação.

3. Materiais e Métodos

Este trabalho foi desenvolvido utilizando a linguagem de programação Python em ambiente Google Colaboratory, empregando bibliotecas especializadas em Aprendizado Profundo e Processamento Digital de Imagens, dentre elas TensorFlow, Keras, OpenCV, NumPy, Matplotlib e Scikit-Learn. Todo o fluxo experimental foi dividido em seis etapas principais: obtenção do conjunto de dados, pré-processamento das imagens, aumento artificial de dados, construção da arquitetura U-Net, treinamento da rede neural e avaliação do modelo. A Figura 1 apresenta o fluxo geral da metodologia utilizada neste trabalho.




Figura 1. Fluxograma da metodologia utilizada.

3.1. Base de Dados

O conjunto de dados utilizado foi o **ISIC 2018 Challenge Dataset**, disponibilizado pela International Skin Imaging Collaboration (ISIC), uma das maiores bases públicas de imagens dermatoscópicas para pesquisa em Inteligência Artificial aplicada à Dermatologia. Cada amostra do conjunto de dados é composta por uma imagem dermatoscópica RGB e uma máscara binária indicando a localização exata da lesão. As máscaras servem como verdade de referência (Ground Truth) durante o treinamento supervisionado da rede neural. No notebook desenvolvido foram utilizadas aproximadamente 100 imagens para treinamento e validação do modelo, sendo divididas em conjuntos independentes para treina-

mento e validação. A Figura 2 apresenta exemplos de imagens presentes no conjunto de dados.




Figura 2. Exemplos de imagens do conjunto ISIC 2018 juntamente com suas respectivas máscaras.

3.2. Pré-processamento

Antes do treinamento da rede neural, todas as imagens passaram por uma etapa de pré-processamento visando padronizar os dados de entrada. Inicialmente, as imagens foram carregadas utilizando a biblioteca OpenCV. Posteriormente, todas foram redimensionadas para a resolução de

$$256 \times 256$$

pixels. Esse procedimento reduz o custo computacional do treinamento e garante que todas as imagens possuam dimensões compatíveis com a arquitetura da rede. Em seguida, realizou-se a normalização dos pixels dividindo seus valores por 255, convertendo o intervalo original de intensidade

$$[0, 255]$$

para

$$[0, 1].$$

A normalização facilita o processo de otimização durante o treinamento, contribuindo para uma convergência mais estável.

3.3. Aumento Artificial de Dados

Como o número de imagens disponíveis para treinamento é relativamente reduzido, foi empregada a técnica de *Data Augmentation*. Essa estratégia consiste em gerar automaticamente novas amostras a partir das imagens originais, reduzindo o risco de sobreajuste

(Overfitting). Durante o treinamento foram aplicadas transformações como rotações, espelhamentos horizontais, espelhamentos verticais, pequenas translações e alterações na orientação das imagens. Todas essas transformações foram realizadas utilizando o *ImageDataGenerator* da biblioteca Keras.

3.4. Arquitetura U-Net

A arquitetura utilizada neste trabalho foi a U-Net, proposta originalmente por Ronneberger et al. [Ronneberger et al. 2015]. Sua estrutura é composta por duas partes principais. A primeira corresponde ao Encoder, responsável pela extração das características presentes nas imagens, formada por sucessivos blocos contendo convoluções 3×3 , função de ativação ReLU e operações de MaxPooling. A segunda parte corresponde ao Decoder, responsável pela reconstrução espacial da imagem segmentada. Nessa etapa são utilizadas operações de UpSampling juntamente com conexões Skip Connections. As Skip Connections unem informações do Encoder ao Decoder, preservando detalhes espaciais importantes para a segmentação precisa das bordas da lesão. A Figura 3 apresenta a arquitetura utilizada.

Model: "functional_1"

Layer (type)	Output Shape	Param #	Connected to
input_layer_1 (InputLayer)	(None, 256, 256, 3)	0	-
conv2d_11 (Conv2D)	(None, 256, 256, 64)	1,792	input_layer_1[0]...
conv2d_12 (Conv2D)	(None, 256, 256, 64)	36,928	conv2d_11[0][0]
max_pooling2d_2 (MaxPooling2D)	(None, 128, 128, 64)	0	conv2d_12[0][0]
conv2d_13 (Conv2D)	(None, 128, 128, 128)	73,856	max_pooling2d_2[...]
conv2d_14 (Conv2D)	(None, 128, 128, 128)	147,584	conv2d_13[0][0]
max_pooling2d_3 (MaxPooling2D)	(None, 64, 64, 128)	0	conv2d_14[0][0]
conv2d_15 (Conv2D)	(None, 64, 64, 256)	295,168	max_pooling2d_3[...]
conv2d_16 (Conv2D)	(None, 64, 64, 256)	590,080	conv2d_15[0][0]
conv2d_transpose_2 (Conv2DTranspose)	(None, 128, 128, 128)	131,200	conv2d_16[0][0]
concatenate_2 (Concatenate)	(None, 128, 128, 256)	0	conv2d_transpose_... conv2d_14[0][0]
conv2d_17 (Conv2D)	(None, 128, 128, 128)	295,040	concatenate_2[0]...
conv2d_18 (Conv2D)	(None, 128, 128, 128)	147,584	conv2d_17[0][0]
conv2d_transpose_3 (Conv2DTranspose)	(None, 256, 256, 64)	32,832	conv2d_18[0][0]
concatenate_3 (Concatenate)	(None, 256, 256, 128)	0	conv2d_transpose_... conv2d_12[0][0]
conv2d_19 (Conv2D)	(None, 256, 256, 64)	73,792	concatenate_3[0]...
conv2d_20 (Conv2D)	(None, 256, 256, 64)	36,928	conv2d_19[0][0]
conv2d_21 (Conv2D)	(None, 256, 256, 1)	65	conv2d_20[0][0]

Total params: 1,862,849 (7.11 MB)

Trainable params: 1,862,849 (7.11 MB)

Figura 3. Arquitetura da U-Net empregada neste trabalho.

3.5. Função de Perda

Para otimizar o treinamento foi utilizada uma função de perda composta pela soma entre Binary Cross Entropy (BCE) e Dice Loss. A utilização conjunta dessas funções melhora significativamente o desempenho em tarefas de segmentação, principalmente quando existe desbalanceamento entre pixels pertencentes ao fundo e à lesão. A função utilizada pode ser representada por

$$Loss = BCE + DiceLoss \quad (1)$$

onde BCE representa o erro de classificação pixel a pixel e Dice Loss mede a diferença entre a máscara prevista e a máscara verdadeira.

3.6. Configuração do Treinamento

Os experimentos foram realizados em ambiente Google Colaboratory utilizando aceleração por GPU. Durante o treinamento foram empregados os hiperparâmetros resumidos na Tabela 1.

Tabela 1. Configuração do treinamento

Parâmetro	Valor
Arquitetura	U-Net
Entrada	$256 \times 256 \times 3$
Otimizador	Adam
Learning Rate	0.001
Batch Size	8
Épocas	20
Função de perda	BCE + Dice Loss
Framework	TensorFlow/Keras
Ambiente	Google Colab

3.7. Avaliação do Modelo

Após o treinamento, o modelo foi avaliado utilizando métricas amplamente empregadas em problemas de segmentação semântica, incluindo Dice Coefficient, Intersection over Union (IoU), Precision, Recall (Sensitivity) e Specificity. Além das métricas quantitativas, também foi realizada uma avaliação qualitativa comparando visualmente as máscaras produzidas pela U-Net com as máscaras reais do conjunto de dados. Para isso foram selecionadas diversas imagens do conjunto de validação, permitindo verificar visualmente a capacidade do modelo em identificar corretamente os contornos das lesões dermatológicas.

4. Resultados

Após o treinamento da arquitetura U-Net, o modelo foi avaliado utilizando o conjunto de validação separado durante a etapa de preparação dos dados. A análise quantitativa foi realizada por meio das métricas Dice Coefficient, Intersection over Union (IoU), Precision, Sensitivity (Recall), Specificity e Loss, amplamente utilizadas em problemas de

segmentação semântica de imagens médicas. Os resultados obtidos demonstram que a rede neural apresentou elevada capacidade de identificar corretamente as regiões correspondentes às lesões dermatológicas, produzindo máscaras bastante semelhantes às máscaras de referência fornecidas pelo conjunto ISIC 2018. A Tabela 2 apresenta os valores finais obtidos durante a avaliação do modelo.

Tabela 2. Resultados obtidos pelo modelo U-Net

Métrica	Resultado
Loss	0.5040
Dice Coefficient	0.7718
IoU	0.6845
Precision	0.9673
Sensitivity (Recall)	0.6989
Specificity	0.9900

Observa-se que o modelo atingiu um Dice Coefficient superior a 77%, indicando elevada sobreposição entre as máscaras produzidas pela rede neural e as máscaras reais do conjunto de dados. O valor de IoU superior a 68% confirma que a interseção entre a região prevista e a região verdadeira foi bastante elevada, demonstrando boa capacidade de segmentação. Outro resultado importante foi a Precision de aproximadamente 96,7%, indicando que praticamente todos os pixels classificados como pertencentes à lesão realmente faziam parte da região lesionada. A Specificity próxima de 99% demonstra que o modelo apresentou excelente capacidade de distinguir corretamente os pixels pertencentes ao fundo da imagem, reduzindo significativamente a ocorrência de falsos positivos.

4.1. Curvas de Aprendizado

Durante o treinamento foi possível observar uma redução gradual da função de perda (Loss), indicando que o modelo convergiu de maneira estável ao longo das épocas. A Figura 4 apresenta a evolução da função de perda durante o treinamento.




Figura 4. Curva da função de perda durante o treinamento.

Observa-se que a perda apresentou comportamento decrescente, indicando que o algoritmo conseguiu aprender progressivamente as características presentes nas imagens dermatoscópicas. A evolução do Dice Coefficient pode ser observada na Figura 5.




Figura 5. Evolução do Dice Coefficient durante o treinamento.

O crescimento contínuo do Dice evidencia que a qualidade das máscaras produzidas aumentou ao longo das épocas, demonstrando aprendizado consistente da arquitetura U-Net. Da mesma forma, a Figura 6 apresenta a evolução da métrica IoU.




Figura 6. Curva da métrica IoU.

Os resultados indicam estabilidade do treinamento e ausência de oscilações significativas, sugerindo que a escolha dos hiperparâmetros foi adequada para o conjunto de dados utilizado.

4.2. Análise Qualitativa

Além da avaliação quantitativa, foi realizada uma inspeção visual das máscaras produzidas pela rede neural. A Figura 8 apresenta exemplos contendo a imagem original, a máscara verdadeira e a máscara prevista pela U-Net.




Figura 7. Enter Caption

Figura 8. Comparação entre imagem original, máscara real e máscara prevista pelo modelo.

Observa-se que o modelo conseguiu delimitar corretamente a maior parte das regiões lesionadas, preservando detalhes importantes das bordas e da forma das lesões. Mesmo em imagens com baixo contraste entre pele saudável e lesão, a arquitetura apresentou boa capacidade de generalização.

5. Discussão

Os resultados experimentais demonstram que a arquitetura U-Net mostrou-se adequada para o problema de segmentação automática de lesões dermatológicas. O elevado valor de Precision indica que o modelo apresentou baixa taxa de falsos positivos, característica extremamente desejável em aplicações médicas, nas quais erros podem comprometer o diagnóstico clínico. Da mesma forma, a Specificity próxima de 99% demonstra excelente desempenho na identificação dos pixels pertencentes ao fundo da imagem, evitando que regiões saudáveis fossem classificadas incorretamente como lesões.

Embora a Sensitivity tenha apresentado valor inferior às demais métricas, esse comportamento é esperado em bases contendo lesões muito pequenas ou com bordas pouco definidas, nas quais a delimitação torna-se significativamente mais difícil. Outro fator que pode ter influenciado esse resultado é o número reduzido de imagens utilizadas durante o treinamento, o que limita parcialmente a capacidade de generalização do modelo. Apesar dessas limitações, o Dice Coefficient superior a 77% e o IoU acima de 68% demonstram que a arquitetura foi capaz de produzir segmentações bastante próximas das máscaras de referência.

Os resultados obtidos são compatíveis com trabalhos encontrados na literatura que utilizam arquiteturas U-Net para segmentação de lesões de pele, reforçando a eficiência da metodologia empregada. Além disso, a utilização de técnicas de aumento artificial de dados contribuiu para reduzir problemas de sobreajuste, aumentando a robustez do modelo frente às variações presentes no conjunto ISIC 2018. De maneira geral, os experimentos evidenciam que a combinação entre pré-processamento adequado, Data Augmentation e arquitetura U-Net constitui uma estratégia eficiente para sistemas inteligentes de apoio ao diagnóstico dermatológico.

6. Conclusão

Neste trabalho foi apresentada uma abordagem baseada na arquitetura U-Net para a segmentação automática de lesões de pele utilizando imagens do conjunto de dados ISIC 2018. O desenvolvimento da metodologia contemplou todas as etapas do processo de Aprendizado Profundo, desde a preparação dos dados até a avaliação quantitativa e qualitativa das segmentações produzidas pelo modelo.

Os experimentos demonstraram que a rede neural foi capaz de identificar corretamente a maior parte das regiões lesionadas, alcançando Dice Coefficient de aproximadamente 0,77, IoU superior a 0,68, precisão de aproximadamente 96,7% e especificidade próxima de 99%. Esses resultados evidenciam que a arquitetura U-Net apresenta elevada capacidade de segmentação, produzindo máscaras bastante semelhantes às máscaras de referência disponibilizadas pelo ISIC 2018.

A utilização conjunta de técnicas de pré-processamento, normalização das imagens, aumento artificial de dados (Data Augmentation) e da função de perda composta por Binary Cross Entropy e Dice Loss contribuiu significativamente para a estabilidade do treinamento e para a capacidade de generalização do modelo.

Apesar dos resultados satisfatórios, algumas limitações ainda podem ser observadas, principalmente na segmentação de lesões muito pequenas ou com baixo contraste em relação à pele saudável. Além disso, o número reduzido de imagens utilizadas durante os experimentos limita parcialmente a capacidade de generalização do modelo para diferentes cenários clínicos.

Como trabalhos futuros, pretende-se ampliar o conjunto de treinamento utilizando um número maior de imagens do ISIC, investigar arquiteturas mais recentes, como Attention U-Net, U-Net++, DeepLabV3+ e TransUNet, além da aplicação de técnicas de aprendizado por transferência e otimização automática de hiperparâmetros. Também se pretende desenvolver uma aplicação web capaz de auxiliar dermatologistas durante o processo de diagnóstico, permitindo a realização da segmentação automática em tempo real.

Os resultados obtidos demonstram que modelos baseados em Deep Learning possuem elevado potencial para atuar como ferramentas de apoio ao diagnóstico médico, contribuindo para diagnósticos mais rápidos, precisos e acessíveis.

Referências

American Cancer Society (2024). Cancer facts and figures 2024. <https://www.cancer.org>.

- Celebi, M. E., Wen, Q., and Iyatomi, H. (2019). A state-of-the-art survey on lesion border detection in dermoscopy images. *Dermatology Research and Practice*.
- Goodfellow, I., Bengio, Y., and Courville, A. (2016). *Deep Learning*. MIT Press.
- LeCun, Y., Bengio, Y., and Hinton, G. (2015). Deep learning. *Nature*, 521(7553):436–444.
- Ronneberger, O., Fischer, P., and Brox, T. (2015). U-net: Convolutional networks for biomedical image segmentation. *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, pages 234–241.
- World Health Organization (2023). Skin cancers. <https://www.who.int/news-room/fact-sheets/detail/skin-cancers>.